PDA

고객을 세그먼테이션하자 [프로젝트]

5-2. 데이터 불러오기

데이터 살펴보기

- **테이블에 있는 10개의 행만 출력하기**

```
select * from `modulabs_project.data` order by InvoiceNo limit 10;
```

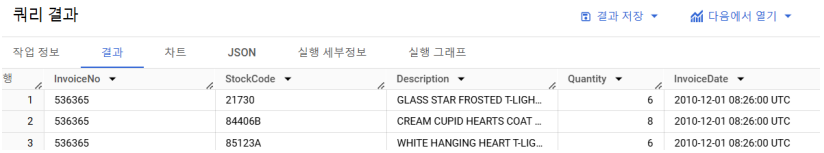

쿼리 결과

결과 저장 다음에서 열기

작업 정보 결과 차트 JSON 실행 세부정보 실행 그래프

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate
1	536365	21730	GLASS STAR FROSTED T-LIGH...	6	2010-12-01 08:26:00 UTC
2	536365	84406B	CREAM CUPID HEARTS COAT ...	8	2010-12-01 08:26:00 UTC
3	536365	85123A	WHITE HANGING HEART T-LIG...	6	2010-12-01 08:26:00 UTC

- **전체 데이터는 몇 행으로 구성되어 있는지 확인하기**

```
select count(*) as num from `modulabs_project.data`  ;
```

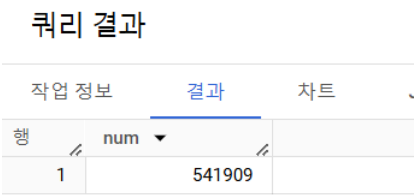

쿼리 결과

작업 정보 결과 차트

행	num
1	541909

데이터 수 세기

- **COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기**

```
select
 count(InvoiceNo) as count_Invoice,
 count(StockCode) as count_StockCode,
 count(Description) as Description,
 count(Quantity) as count_Quantity,
 count(InvoiceDate) as count_InvoiceDate,
 count(UnitPrice) as count_UnitPrice,
 count(CustomerID) as count_CustomerID,
 count(Country) as count_Country
 from `modulabs_project.data`;
```

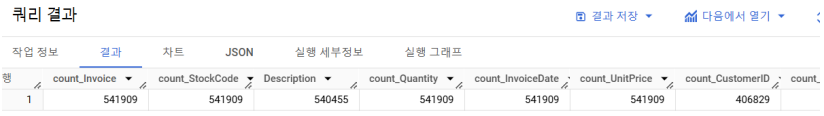

쿼리 결과

결과 저장 다음에서 열기

작업 정보 결과 차트 JSON 실행 세부정보 실행 그래프

행	count_Invoice	count_StockCode	Description	count_Quantity	count_InvoiceDate	count_UnitPrice	count_CustomerID	count_
1	541909	541909	540455	541909	541909	541909	406829	

5-4. 데이터 전처리 방법(1): 결측치 제거

컬럼 별 누락된 값의 비율 계산

- **각 컬럼 별 누락된 값의 비율을 계산**
  - **각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기**

```
SELECT 'InvoiceNo' as column_name,

    ROUND(SUM(CASE WHEN InvoiceNo IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percent

    select 'StokeCode' as column_name, ROUND(SUM(CASE WHEN StockCode IS NULL THEN 1 ELSE 0 END) / CO

FROM modulabs_project.data ;

-- 첫 행을 invoiceno 라고 이름 지어주고 그 옆의 값을 INVOICENO에 대한 결측치 값을 나타내는 방식으로 진행함.
--GROUP BY로 진행했으면 GROUP 한 값에 따라 일일이 0,1여부 판단하는 테이블이 길게 나타났을 것.
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보

행	column_name	missing_percentage
1	InvoiceNo	0.0
2	StokeCode	0.0

결측치 처리 전략

- `StockCode = '85123A'` 의 `Description` 을 추출하는 쿼리문을 작성하기

```
SELECT distinct Description
FROM modulabs_project.data where StockCode = '85123A' ;
```

쿼리 결과

작업 정보 | 결과 | 차트

행	Description
1	?
2	wrongly marked carton 22804
3	CREAM HANGING HEART T-LIG...
4	WHITE HANGING HEART T-LIG...

결측치 처리

- **DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시**

```
UPDATE modulabs_project.data
SET Description = NULL
WHERE Description LIKE '%?%';


delete
FROM modulabs_project.data where Description is NULL or CustomerID is null ;
```

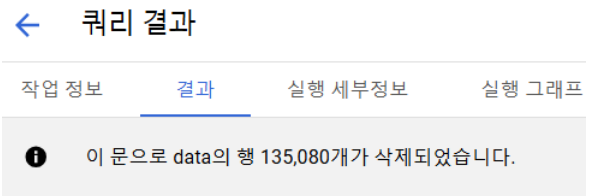

5-5. 데이터 전처리(2): 중복값 처리

중복값 확인

- **중복된 행의 수를 세어보기**
  - **8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기**

```
SELECT count (*)
FROM(
  select 1 from modulabs_project.data
group by InvoiceNo, StockCode, Description,
Quantity, InvoiceDate, UnitPrice,CustomerID, Country
having count(*)>1) as ccount;
```

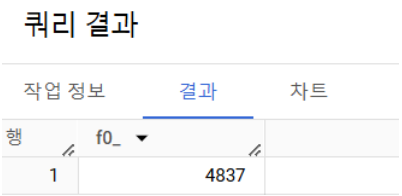

중복값 처리

- **중복값을 제거하는 쿼리문 작성하기**
  - **CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(*)을 DISTINCT 한 데이터로 업데이트**

```
-- 빅쿼리에서 rowid가 없고, 여러 열이 있는 DELETE ... WHERE ... IN을 지원하지 않았다..

create or replace table modulabs_project.data as
select *
from
 ( select *,
           ROW_NUMBER() OVER (
               PARTITION BY
                   InvoiceNo,
                   StockCode,
                   Description,
                   CAST(Quantity AS STRING),
                   InvoiceDate,
                   CAST(UnitPrice AS STRING),
                   CustomerID,
                   Country
               ORDER BY CURRENT_TIMESTAMP()
           ) AS row_num
    FROM modulabs_project.data
)
```

```
WHERE row_num = 1;

-- CAST(문자열로 수량) 및 CAST(문자열로 단가):
-- FLOAT64 열(Quantity 및 UnitPrice)을 STRING으로 변환하여 PARTITION BY 절에서 사용할 수 있도록 합니다.
```

쿼리 결과

작업 정보 | 결과 | 실행 세부정보

이 문으로 이름이 data인 테이블이 교체되었습니

5-6. 데이터 전처리(3): 오류값 처리

`InvoiceNo` 살펴보기

- **고유(unique)한 `InvoiceNo`의 개수를 출력하기**

```
select count(distinct InvoiceNo) as ccount
from modulabs_project.data
where InvoiceNo is not null;
```

쿼리 결과

작업 정보 | 결과 | 차트

행	ccount
1	22190

- **고유한 `InvoiceNo`를 앞에서부터 100개를 출력하기**

```
select distinct InvoiceNo as InvoiceNo
from modulabs_project.data
where InvoiceNo is not null limit 100;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSO

행	InvoiceNo
1	574301
2	C575531
3	557305
4	543008

- **`InvoiceNo`가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)**

```
SELECT distinct InvoiceNo as InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, Cu
FROM modulabs_project.data
```

```
WHERE InvoiceNo is not null and InvoiceNo like '%C%'
LIMIT 100;
```

쿼리 결과

결과 저장 다음에

작업 정보 결과 차트 JSON 실행 세부정보 실행 그래프

행	InvoiceNo	StockCode	Description	Quantity	InvoiceDate
1	C575531	22960	JAM MAKING SET WITH JARS	-4	2011-11-10 11:
2	C558080	22847	BREAD BIN DINER STYLE IVORY	-1	2011-06-26 11:
3	C558080	22840	ROUND CAKE TIN VINTAGE RED	-1	2011-06-26 11:

- **구매 건 상태가 `Canceled` 인 데이터의 비율(%) - 소수점 첫번째 자리까지**

```
with tr as (
  SELECT distinct InvoiceNo as InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice,
FROM modulabs_project.data
WHERE InvoiceNo is not null
)

SELECT
    ROUND(
        100 * SUM(CASE WHEN InvoiceNo LIKE '%C%' THEN 1 ELSE 0 END) / COUNT( InvoiceNo),
        1
    ) AS percentage
FROM tr;
-- 이거 with 문 사용하지 않고 더 간단하게 코드 작성 가능할 것 같은데 시도하다 막힘..
-- union all 사용해서 진행하는 방법 시도하다가 눈이 아파와서 중도포기..
--처음에 sum 내부에 distinct 사용하니 해당 case 값들을 distinct 시켜서 값이 1이 나와서 해결하느라 많이 해맴 주의
```

쿼리 결과

작업 정보 결과 차트 JSON

행	percentage
1	2.2

`StockCode` 살펴보기

- **고유한 `StockCode` 의 개수를 출력하기**

```
select count(distinct StockCode) as ccount
from modulabs_project.data
where StockCode is not null;
```

쿼리 결과

작업 정보 결과 차트 JSON

행	ccount
1	3684

- **어떤 제품이 가장 많이 판매되었는지 보기 위하여 `StockCode` 별 등장 빈도를 출력하기**
  - 상위 10개의 제품들을 출력하기

```
SELECT StockCode, COUNT(*) AS sell_cnt
FROM modulabs_project.data
group by StockCode
ORDER BY sell_cnt DESC
limit 10;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실

행	StockCode	sell_cnt
1	85123A	2065
2	22423	1894
3	85099B	1659
4	47566	1409

- `StockCode` **의 문자열 내 숫자의 길이를 구해보기**

```
WITH UniqueStockCodes AS (
  SELECT DISTINCT StockCode
  FROM modulabs_project.data
)
SELECT
  LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count,
  COUNT(*) AS stock_cnt
FROM UniqueStockCodes
GROUP BY number_count
ORDER BY stock_cnt DESC;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON

행	number_count	stock_cnt
1	5	3676
2	0	7
3	1	1

- `StockCode` **의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값**들에는 어떤 코드들이 들어가 있는지 출력하기

```
SELECT DISTINCT StockCode, number_count
FROM (
  SELECT StockCode,
    LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
  FROM modulabs_project.data
)
WHERE number_count between 0 and 1 order by StockCode;

--FROM 값에 nnumber_count를 정의해놔서 where에 쉽게 사용 가능했다. 참고하기.
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 시

행	StockCode	number_count
1	BANK CHARGES	0
2	C2	1
3	CRUK	0
4	D	0

- `StockCode` **의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트**인지 구하기 (소수점 두 번째 자리까지)

```
WITH nc AS (
    SELECT DISTINCT
        StockCode,
        LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
    FROM modulabs_project.data
    WHERE LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) BETWEEN 0 AND 1
    ORDER BY StockCode
)
SELECT
    ROUND(
        100 * COUNT(n.number_count) / COUNT(m.StockCode),
        2
    ) AS percentage
FROM modulabs_project.data m
LEFT JOIN nc n ON m.StockCode = n.StockCode;
```

쿼리 결과

작업 정보 | 결과 | 차트

행	percentage
1	0.48

- **제품과 관련되지 않은 거래 기록을 제거하기**

```
DELETE FROM modulabs_project.data
WHERE StockCode IN (
  SELECT DISTINCT StockCode
  FROM (
      SELECT DISTINCT
        StockCode,
        LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
    FROM modulabs_project.data
    WHERE LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) BETWEEN 0 AND 1
    ORDER BY StockCode
));
```

쿼리 결과

작업 정보 | 결과 | 실행 세부정보 | 실행 그리

이 문으로 data의 행 1,915개가 삭제되었습니다.

`Description` 살펴보기

- **고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기**

```
SELECT Description, COUNT(*) AS description_cnt
FROM modulabs_project.data
group by Description
limit 30;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보

행	Description	description_cnt
1	ASSORTED COLOUR BIRD ORN...	1405
2	EMBROIDERED RIBBON REEL S...	63
3	EMBROIDERED RIBBON REEL R...	49
4	TRADITIONAL CHRISTMAS RIB...	272

- **대소문자가 혼합된 Description이 있는지 확인하기**

```
SELECT DISTINCT Description
FROM modulabs_project.data
WHERE REGEXP_CONTAINS(Description, r'[a-z]');

-- 대문자가 있는것은 확인했으니 소문자 있는거것만 분류해서 대소문자 존재 여부 확인
```

쿼리 결과

작업 정보 | 결과 | 차트 | JS

행	Description
1	BAG 125g SWIRLY MARBLES
2	3 TRADITIONAl BISCUIT CUTTE...
3	BAG 250g SWIRLY MARBLES
4	ESSENTIAL BALM 3.5g TIN IN ...

- **서비스 관련 정보를 포함하는 행들을 제거하기**

```
DELETE
FROM modulabs_project.data
WHERE
 Description like 'Next Day Carriage' or Description like 'High Resolution Image';
```

쿼리 결과

작업 정보 | 결과 | 실행 세부정보 | 실행 .

이 문으로 data의 행 83개가 삭제되었습니다.

[결과 이미지를 넣어주세요]

- **대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기**

```
CREATE OR REPLACE TABLE modulabs_project.data AS
SELECT
    * EXCEPT (Description),
    UPPER(Description) AS Description
FROM
    modulabs_project.data;

-- upper() 함수로 대문자로 바꿔버리기 가능
-- gpt는 그런거 없다고 했던 함수 '* EXCEPT (Description)'... 역시 존재했다..
```

쿼리 결과

작업 정보 | 결과 | 실행 세부정보 | 실행 그래프

이 문으로 이름이 data인 테이블이 교체되었습니다.

`UnitPrice` 살펴보기

- `UnitPrice` **의 최솟값, 최댓값, 평균을 구하기**

```
SELECT min(UnitPrice) AS min_price, max(UnitPrice) AS max_price, avg(UnitPrice) AS avg_price
FROM modulabs_project.data;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	min_price	max_price	avg_price
1	0.0	649.5	2.904956757405...

- **단가가 0원인 거래의 개수, 구매 수량(`Quantity`)의 최솟값, 최댓값, 평균 구하기**

```
SELECT count(UnitPrice = 0) AS cnt_quantity, min(Quantity) AS min_quantity, max(Quantity) AS max_qua
FROM modulabs_project.data
WHERE UnitPrice = 0.0;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	cnt_quantity	min_quantity	max_quantity	avg_quantity
1	33	1	12540	420.5151515151...

- `UnitPrice = 0` 를 제거하고 일관된 데이터셋을 유지하기

```
CREATE OR REPLACE TABLE modulabs_project.data AS
SELECT *
FROM modulabs_project.data
WHERE UnitPrice != 0.0;
```

쿼리 결과

작업 정보 | 결과 | 실행 세부정보 | 실행 그래프

이 문으로 이름이 data인 테이블이 교체되었습니다.

5-7. RFM 스코어

Recency

- `InvoiceDate` 컬럼을 연월일 자료형으로 변경하기

```
SELECT date(InvoiceDate) AS InvoiceDay, *
FROM modulabs_project.data;
```

쿼리 결과 | 결과 저장 | 다음에서 열기

작업 정보 | 결과 | 차트 | JSON | 실행 세부정보 | 실행 그래프

행	InvoiceDay	InvoiceNo	StockCode	Quantity	InvoiceDate	U
1	2011-10-31	C573502	21888	-2	2011-10-31 12:02:00 UTC	
2	2011-05-17	553546	21888	144	2011-05-17 15:42:00 UTC	
3	2010-12-08	C537860	21888	-4	2010-12-08 16:15:00 UTC	

- **가장 최근 구매 일자를 MAX() 함수로 찾아보기**

```
SELECT
    MAX(DATE(InvoiceDate)) OVER () AS most_recent_date,
    DATE(InvoiceDate) AS InvoiceDay,
    *
FROM modulabs_project.data;

--OVER () 구문을 사용하여 전체 데이터에 대해 가장 최근 날짜를 계산. OVER ()는 집계 함수와 함께 사용되어 전체 행에 대해
-- OVER()는 행을 그룹화하거나 축소하지 않고 집계 함수를 적용하므로 OVER()를 사용할 때 GROUP BY가 필요하지 않습니다.
-- **GROUP BY**를 사용하면 SQL은 지정된 열을 기준으로 행을 그룹화하고 그룹당 하나의 결과를 반환합니다. 즉, GROUP BY
```

쿼리 결과

결과 저장 다음에서 열

작업 정보 결과 차트 JSON 실행 세부정보 실행 그래프

행	most_recent_date	InvoiceDay	InvoiceNo	StockCode	Quantity	InvoiceDat
1	2011-12-09	2011-10-11	570660	21260	72	2011-10-1
2	2011-12-09	2011-08-08	562608	22197	200	2011-08-0
3	2011-12-09	2011-10-07	570168	16011	88	2011-10-0

- **유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기**

```
SELECT
    CustomerID,
    max(InvoiceDate) AS InvoiceDay
FROM modulabs_project.data
group by CustomerID;
```

쿼리 결과

작업 정보 결과 차트 JSON 실행 세부정보

행	CustomerID	InvoiceDay
1	14808	2011-10-31 12:21:00 UTC
2	12415	2011-11-15 14:22:00 UTC
3	16252	2010-12-08 16:15:00 UTC
4	14156	2011-11-30 10:54:00 UTC

- **가장 최근 일자(`most_recent_date`)와 유저별 마지막 구매일(`InvoiceDay`)간의 차이를 계산하기**

```
SELECT
  CustomerID,
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM modulabs_project.data
  GROUP BY CustomerID
);
```

쿼리 결과

작업 정보 결과 차트 JSON 실행 서

행	CustomerID	recency
1	13805	52
2	16676	33
3	12627	10
4	17799	22

- **최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 `user_r` 이라는 이름의 테이블로 저장하기**

```
CREATE OR REPLACE TABLE modulabs_project.user_r AS
SELECT
  CustomerID,
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
```

```
FROM (
  SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM modulabs_project.data
  GROUP BY CustomerID
);
```

user_r 쿼리 공유

스키마 세부정보 미리보기

행	CustomerID	recency
1	12526	0
2	18102	0
3	12433	0
4	15311	0
5	17754	0
6	15344	0
7	15910	0
8	12985	0
9	14446	0
10	16705	0

Frequency

- **고객마다 고유한 InvoiceNo의 수를 세어보기**

```
SELECT
  CustomerID,
  count(distinct InvoiceNo) AS purchase_cnt
FROM modulabs_project.data
group by CustomerID  ;
```

쿼리 결과

작업 정보 결과 차트 JSON

행	CustomerID	purchase_cnt
1	14808	14
2	12415	24
3	16252	1
4	14156	64

- **각 고객 별로 구매한 아이템의 총 수량 더하기**

```
SELECT
    CustomerID,
    SUM(Quantity) AS item_cnt
FROM  modulabs_project.data
GROUP BY CustomerID;
```

쿼리 결과

작업 정보 | 결과 | 차트 | JSON

행	CustomerID	item_cnt
1	14808	2028
2	12415	76946
3	16252	-158
4	14156	56896

- **전체 거래 건수 계산와 구매한 아이템의 총 수량 계산의 결과를 합쳐서 `user_rf` 라는 이름의 테이블에 저장하기**

```
CREATE OR REPLACE TABLE modulabs_project.user_rf AS

-- (1) 전체 거래 건수 계산
WITH purchase_cnt AS (
 SELECT
  CustomerID,
  count(distinct InvoiceNo) AS purchase_cnt
FROM modulabs_project.data
group by CustomerID
),

-- (2) 구매한 아이템 총 수량 계산
item_cnt AS (
 SELECT
    CustomerID,
    SUM(Quantity) AS item_cnt
FROM  modulabs_project.data
GROUP BY CustomerID
)

-- 기존의 user_r에 (1)과 (2)를 통합
SELECT
  pc.CustomerID,
  pc.purchase_cnt,
  ic.item_cnt,
  ur.recency
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
  ON pc.CustomerID = ic.CustomerID
JOIN modulabs_project.user_r AS ur
  ON pc.CustomerID = ur.CustomerID;
```

user_rf 쿼리 공유 복사 스냅샷 삭

스키마 세부정보 미리보기 테이블 탐색기 미리보기 통계

행	CustomerID	purchase_cnt	item_cnt	recency
1	12713	1	505	0
2	12792	1	215	256
3	18010	1	60	256
4	15083	1	38	256
5	13436	1	76	1
6	13298	1	96	1
7	14569	1	79	1
8	15520	1	314	1
9	14476	1	110	257
10	13357	1	321	257

Monetary

- **고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)**

```
SELECT
  CustomerID,
  round(sum(Quantity*UnitPrice),1) AS user_total
FROM modulabs_project.data
group by CustomerID;
```

쿼리 결과

작업 정보 결과 차트 JSON

행	CustomerID	user_total
1	14808	2277.8
2	12415	123638.2
3	16252	-295.1
4	14156	113685.8

- **고객별 평균 거래 금액 계산**
  - **고객별 평균 거래 금액을 구하기 위해 1) `data` 테이블을 `user_rf` 테이블과 조인(LEFT JOIN) 한 후, 2) `purchase_cnt`로 나누어서 3) `user_rfm` 테이블로 저장하기**

```
CREATE OR REPLACE TABLE modulabs_project.user_rfm AS
SELECT
  rf.CustomerID AS CustomerID,
  rf.purchase_cnt,
  rf.item_cnt,
  rf.recency,
  ut.user_total,
  round(ut.user_total / rf.purchase_cnt, 1) AS user_average
FROM modulabs_project.user_rf rf
LEFT JOIN (
  -- 고객 별 총 지출액
  SELECT
```

```
    CustomerID,
  round(sum(Quantity*UnitPrice),1) AS user_total
  FROM modulabs_project.data
  group by CustomerID
) ut
ON rf.CustomerID = ut.CustomerID;
```

user_rfm 쿼리 공유 복사 스냅샷 삭제 내보내기

스키마 세부정보 미리보기 테이블 탐색기 미리보기 통계 계보 데이터

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	505	0	794.5	794.5
2	15083	1	38	256	88.2	88.2
3	18010	1	60	256	174.8	174.8
4	12792	1	215	256	344.5	344.5
5	13436	1	76	1	196.9	196.9
6	13298	1	96	1	360.0	360.0
7	14569	1	79	1	227.4	227.4
8	15520	1	314	1	343.5	343.5
9	14476	1	110	257	193.0	193.0
10	13357	1	321	257	609.4	609.4
11	15195	1	1404	2	3861.0	3861.0

RFM 통합 테이블 출력하기

- **최종 user_rfm 테이블을 출력하기**

```
select * from modulabs_project.user_rfm;
```

쿼리 결과 결과 저장 다

작업 정보 결과 차트 JSON 실행 세부정보 실행 그래프

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	505	0	794.5	794.5
2	15083	1	38	256	88.2	88.2
3	18010	1	60	256	174.8	174.8
4	12792	1	215	256	344.5	344.5

5-8. 추가 Feature 추출

1. 구매하는 제품의 다양성

- **1) 고객 별로 구매한 상품들의 고유한 수를 계산하기**
  2) `user_rfm` **테이블과 결과를 합치기**
  3) `user_data` **라는 이름의 테이블에 저장하기**

```
CREATE OR REPLACE TABLE modulabs_project.user_data AS
WITH unique_products AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT StockCode) AS unique_products
  FROM modulabs_project.data
  GROUP BY CustomerID
)
SELECT ur.*, up.* EXCEPT (CustomerID)
FROM modulabs_project.user_rfm AS ur
```

```
JOIN unique_products AS up
ON ur.CustomerID = up.CustomerID;
```

user_data 쿼리 공유 복사 스냅샷 삭제 내보내기

스키마 세부정보 미리보기 테이블 탐색기 미리보기 통계 계보 데이터 프로필

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_products
1	14424	1	48	17	322.1	322.1	1
2	15657	1	24	22	30.0	30.0	1
3	16738	1	3	297	3.8	3.8	1
4	17986	1	10	56	20.8	20.8	1
5	16138	1	-1	368	-8.0	-8.0	1
6	18113	1	72	368	76.3	76.3	1
7	17331	1	16	123	175.2	175.2	1
8	16323	1	50	196	207.5	207.5	1

2. 평균 구매 주기

- **고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)**
  - **균 구매 소요 일수를 계산하고, 그 결과를 `user_data` 에 통합**

```
CREATE OR REPLACE TABLE modulabs_project.user_data AS
WITH purchase_intervals AS (
  -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
  SELECT
    CustomerID,
    CASE WHEN ROUND(AVG(interval_), 2) IS NULL THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_inte
  FROM (
    -- (1) 구매와 구매 사이에 소요된 일수
    SELECT
      CustomerID,
      DATE_DIFF(InvoiceDate, LAG(InvoiceDate) OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DAY)
    FROM
      modulabs_project.data
    WHERE CustomerID IS NOT NULL
  )
  GROUP BY CustomerID
)

SELECT u.*, pi.* EXCEPT (CustomerID)
FROM modulabs_project.user_data AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;
```

user_data 쿼리 공유 복사 스냅샷 삭제 내보내기

스키마 세부정보 미리보기 테이블 탐색기 미리보기 통계 계보 데이터 프로필 데이터 품질

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_products	average_interval
1	14432	6	2013	9	2248.5	374.8	256	0.2
2	12428	11	3477	25	6366.0	578.7	256	0.87
3	13268	14	3525	17	3105.7	221.8	256	0.56
4	14351	1	12	164	51.0	51.0	1	0.0
5	13302	1	5	155	63.8	63.8	1	0.0
6	15488	1	72	92	76.3	76.3	1	0.0
7	15562	1	39	351	134.6	134.6	1	0.0
8	16323	1	50	196	207.5	207.5	1	0.0

3. 구매 취소 경향성

- **고객의 취소 패턴 파악하기**
  1) 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수

2) 취소 비율(cancel_rate) : 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율

- **취소 빈도와 취소 비율을 계산하고 그 결과를 `user_data` 에 통합하기 (취소 비율은 소수점 두번째 자리)**

```
CREATE OR REPLACE TABLE modulabs_project.user_data AS

WITH TransactionInfo AS (
  SELECT
    CustomerID,
    count(CustomerID) AS total_transactions,
    sum(CASE WHEN Quantity < 0 THEN 1 ELSE 0 END) AS cancel_frequency
  FROM modulabs_project.data
  group by CustomerID
)
SELECT u.*, t.* EXCEPT(CustomerID), round(t.cancel_frequency / t.total_transactions * 100, 2) AS cancel
FROM modulabs_project.user_data AS u
LEFT JOIN TransactionInfo AS t
ON t.CustomerID =u.CustomerID ;

-- 이거 맞는거 같은데...
```

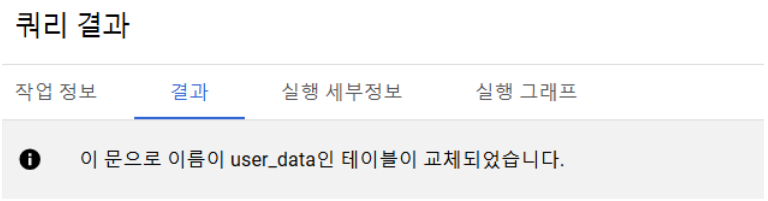

- **다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 `user_data` 를 출력하기**

```
select * from modulabs_project.user_data;
```

후기:

전날에 문제 푸는 동안 나타나는 장벽에 열심히 박아가면서 코드를 작성하여서 그런지 그럭저럭 풀리는 느낌이 듦.

유의미한 데이터를 찾아서 분석하는 기준에 있어서 분석가의 안목이 중요한 부분이라는 것을 알 수 있는 교육과정이였다.